



UNIVERSITA' DEGLI STUDI DI  
NAPOLI FEDERICO II

Scuola Politecnica e delle Scienze di Base  
Corso di Laurea Magistrale in Ingegneria Informatica

Progetto del corso di Cognitive Computing Systems

## Applicazione dei sistemi cognitivi come supporto alle metanalisi standard e network relative il glioblastoma multifforme

Anno Accademico 2020/2021

**Prof. Paolo Maresca**

**Studenti**

De Cegli Luigi - matr. M63000713

Imperatore Antonio - matr. M63001096

# Indice

|          |                                                              |           |
|----------|--------------------------------------------------------------|-----------|
| <b>1</b> | <b>Definizione del problema</b>                              | <b>2</b>  |
| 1.1      | Sistemi di calcolo cognitivo . . . . .                       | 2         |
| 1.2      | Dominio applicativo . . . . .                                | 4         |
| 1.2.1    | Glioblastoma multiforme . . . . .                            | 4         |
| 1.2.2    | Meta-analisi e ricerca svolta per il trattamento del GBM . . | 5         |
| 1.3      | Analisi del progetto . . . . .                               | 8         |
| <b>2</b> | <b>Progettazione del sistema cognitivo</b>                   | <b>11</b> |
| 2.1      | Definizione della pipeline di lavoro . . . . .               | 11        |
| 2.2      | Data preprocessing . . . . .                                 | 13        |
| 2.2.1    | Conversione attraverso i moduli Python . . . . .             | 15        |
| 2.2.2    | Conversione mediante motore OCR . . . . .                    | 16        |
| 2.2.3    | Conversione mediante approccio data-model . . . . .          | 24        |
| 2.2.4    | Conversione mediante approccio data-driven . . . . .         | 25        |
| 2.2.5    | Risultati della fase di preprocessing . . . . .              | 28        |
| 2.3      | Creazione del modello in Watson Knowledge Studio . . . . .   | 28        |
| 2.3.1    | Definizione del type system . . . . .                        | 28        |
| 2.3.2    | Machine Learning Model . . . . .                             | 32        |
| 2.4      | Deploy . . . . .                                             | 35        |
| 2.5      | Data Collection in Watson Discovery . . . . .                | 36        |
| 2.5.1    | Creazione della Data Collection . . . . .                    | 36        |
| 2.5.2    | Data Configuration . . . . .                                 | 37        |
| 2.5.3    | Schema dei dati . . . . .                                    | 40        |

|          |                                                              |           |
|----------|--------------------------------------------------------------|-----------|
| 2.5.4    | Discovery Query . . . . .                                    | 41        |
| <b>3</b> | <b>Analisi ed interpretazione dei risultati</b>              | <b>43</b> |
| 3.1      | Analisi dei risultati tra le versioni del progetto . . . . . | 43        |
| 3.1.1    | Confronto sul dataset . . . . .                              | 43        |
| 3.1.2    | Confronto sul preprocessing dei dati . . . . .               | 44        |
| 3.1.3    | Confronto sulle prestazioni dei modelli . . . . .            | 44        |

# Applicazione dei sistemi cognitivi come supporto alle metanalisi standard e network relative il glioblastoma multiforme

## Premessa

L'approccio oncologico tradizionale, che si avvale di due tipologie di meta-analisi (standard e network), non ha prodotto per alcun trattamento risultati, statisticamente significativi, tali da poter dimostrare un'efficacia terapeutica maggiore di uno rispetto ai restanti.

Per la risoluzione del problema viene proposta una strategia innovativa basata sui sistemi cognitivi che, mediante un'architettura *ad hoc*, ha l'obiettivo di ottenere risultati statisticamente significativi.

L'architettura si compone di due parti fondamentali: la prima in grado di produrre, attraverso gli articoli scientifici e le ricerche derivate da una biblioteca vastissima, quali PubMed e fonti di dati non strutturati di cartelle cliniche, risultati con capacità correlazionale con strategie statistiche ampiamente validate che costituiscono la seconda parte fondamentale dell'architettura.

Poiché il problema alla base del classico approccio oncologico è da ricondursi alla troppa rigida selezione degli studi clinici, si suggerisce un rilassamento dei vincoli e di conseguenza una ridefinizione dei criteri di inclusione. I criteri ridefiniti, mappati sul sistema cognitivo mediante entità e relazioni giustificate, cioè legittimate da un evidente nesso logico con gli stessi criteri, permetteranno di arricchire il recupero di documenti in termini di precisione e completezza rispetto alla scarsa selezione già ottenuta con tecniche tradizionali come la metanalisi.

Il task dell'elaborato consiste nell'implementare un cognitive computing system per esplorare documenti scientifici relativi al glioblastoma multiforme attraverso gli strumenti forniti dal servizio IBM Cloud. Nel particolare, l'applicazione dei servizi cognitivi è mirata a supportare la meta-analisi tradizionale col fine di individuare la migliore terapia medica per curare il glioblastoma. Dunque, si desidera automatizzare l'estrazione di tutte le informazioni rilevanti contenute nei documenti scritti in linguaggio naturale per confrontare statisticamente l'efficacia delle diverse terapie oncologiche in modo da fornire una terapia adeguata per la cura del glioblastoma multiforme refrattario (in pazienti adulti).

# Capitolo 1

## Definizione del problema

### 1.1 Sistemi di calcolo cognitivo

I **sistemi informatici basati sul cognitive computing** sono progettati e sviluppati per interagire in modo naturale con gli esseri umani, svolgendo conversazioni personalizzate con essi. L'obiettivo è fare in modo che macchine e utenti, attraverso il continuo scambio di informazioni, riescano ad interagire in modo sempre più efficiente con il mondo esterno di quanto riescano a farlo separatamente. Infatti, l'impiego delle macchine nelle attività della vita umana è mirato a **prendere decisioni migliori**, sia nel caso di singoli individui che di aziende, mediante l'elaborazione attenta dei **Big Data**, le cui caratteristiche sono definite dal paradigma 5V:

- **volume**: riguarda la capacità di acquisire, memorizzare ed accedere a grandi moli di dati (strutturati e non strutturati) che non sono gestibili attraverso i tradizionali database;
- **velocity**: si riferisce sia alla rapidità con cui i dati vengono generati, sia alle veloci tempistiche con cui l'analisi deve essere effettuata (in modo da ottenere vantaggi rispetto alla concorrenza);
- **variety**: si riferisce al fatto che i dati provengono da fonti eterogenee (come sensori, log, eventi, voice, social media, etc.) e che hanno diversa natura (dati strutturati, non strutturati o semi-strutturati);
- **veracity**: la veridicità dei dati rappresenta un requisito fondamentale, in quanto essi sono fondamentali per le aziende;

- **value**: se gestiti in maniera corretta, i dati possono produrre un guadagno o un vantaggio competitivo per una organizzazione.



**Figura 1.1:** Paradigma 5V dei Big Data

Dunque, un Cognitive Computing System è un modello basato sul modo di ragionare dell'essere umano, ovvero sul **processo cognitivo** (metodo induttivo), che consiste nell'osservazione di un fenomeno al fine di prendere una decisione e che si compone delle seguenti fasi:

1. si osservano i fenomeni visibili e si raccolgono le prove oggettive (dati);
2. si usa la propria conoscenza per interpretare ciò che si osserva, generando ipotesi su ciò che viene osservato;
3. si valuta quali ipotesi sono giuste e quali sono sbagliate;
4. si prende la decisione scegliendo l'ipotesi che si ritiene giusta e agendo di conseguenza.


Tali sistemi, basati sul **Machine Learning (ML)**, sono destinati a rivoluzionare molti aspetti della vita quotidiana. Un dominio applicativo impattato da questi sistemi è quello della **medicina**. Infatti, attualmente, sono in costruzione sistemi cognitivi in grado di individuare il trattamento più adatto per un paziente in base alle proprie patologie: il loro impiego permetterebbe di migliorare l'esperienza medica, o addirittura potrebbe essere determinante per salvare la vita di malati gravi che necessitano di un intervento urgente.

## 1.2 Dominio applicativo

Il **dominio applicativo** trattato in questa documentazione è quello della **medicina**. In particolare, si focalizza l'attenzione sul glioblastoma, un tumore che colpisce il sistema nervoso centrale, e sulla meta-analisi, una tecnica clinico-statistica per rispondere ad un determinato quesito clinico. Prima di definire in maniera chiara il problema e gli obiettivi del progetto, si riporta una descrizione di questi 2 elementi principali e della ricerca svolta per migliorare la comprensione del dominio e caratterizzarlo in maniera adeguata.

### 1.2.1 Glioblastoma multiforme

Il **glioblastoma (GBM)**, conosciuto anche come **glioblastoma multiforme o astrocitoma di grado IV**, è una forma molto aggressiva di tumore che colpisce il sistema nervoso centrale. Nonostante si manifesti per lo più nel cervello, il tumore può anche presentarsi nel midollo spinale, nel cervelletto e nel tronco cerebrale. Esso **ha origine** da un gruppo di cellule, detto **glia**, che svolge una funzione di sostegno per le cellule nervose, ovvero i neuroni. Sebbene possa manifestarsi in qualsiasi età, inclusa l'infanzia, il tumore insorge più frequentemente in età adulta, tra i 45 e i 75 anni. In particolare, l'incidenza, ovvero la frequenza con cui si manifestano nuovi casi, è superiore negli uomini che nelle donne e nei caucasici rispetto ad altre etnie. La **cura di questo tumore è molto difficile**, anche se la **terapia permette di rallentarne la progressione e ridurne i sintomi**.



**Figura 1.2:** Risonanza magnetica del glioblastoma multiforme

## 1.2.2 Meta-analisi e ricerca svolta per il trattamento del GBM

La **meta-analisi** è una tecnica clinico-statistica quantitativa che permette di combinare i dati di più studi condotti su di uno stesso argomento, generando un unico dato conclusivo per rispondere a uno specifico quesito clinico. Essa risulta utile quando esiste incertezza nella valutazione di efficacia di un trattamento, o perché i risultati dei singoli studi non sono univoci oppure perché i singoli studi sono effettuati su pochi pazienti e considerati scarsamente affidabili. L'**approccio oncologico standard, applicato alla ricerca svolta per il trattamento del GBM**, si basa sull'ausilio di 2 tipologie di meta-analisi e prevede l'impiego di **3 end-points** caratteristici della ricerca oncologica:

- **Overall Survival (OS)**: è la sopravvivenza globale, definita come il periodo di tempo che intercorre tra l'inizio del trattamento e la morte per qualsiasi causa (end-point primario);
- **Progression Free Survival (PFS)**: è la sopravvivenza libera da progressione, definita come il tempo dalla randomizzazione alla progressione della malattia o alla morte a causa della stessa, a seconda di quale avviene prima (end-point secondario);
- **Overall Response Rate (ORR)**: è il tasso di risposta globale, utilizzato per valutare al meglio lo stato effettivo del paziente e definito in seguito alla valutazione dei criteri di MacDonald o RANO (ulteriore end-point secondario).

Per quanto concerne le **tipologie di meta-analisi**, esse sono:

- **meta-analisi standard**;
- **meta-analisi network**.

Le **fonti di dati utilizzate per la ricerca** sono:

- database PubMed e Google Scholar;
- archivi online degli incontri annuali dell'European Society for Medical Oncology (ESMO) e dell'American Society of Clinical Oncology (ASCO);
- elenchi di riferimento delle linee guida più recenti dell'American National Comprehensive Cancer Network (NCCN), dell'European Society for Medical Oncology (ESMO) e dell'Associazione Italiana di Oncologia Medica (AIOM).



I **criteri di inclusione** dei dati scelti per l'analisi degli studi sono 3:

1. studi clinici randomizzati riguardanti GBM refrattario/recidivante;
2. studi di fase II o III;
3. disponibilità o computabilità dai dati pubblicati di hazard ratio (HR) per OS e/o PFS e/o odds ratio (OR) per ORR.

Complessivamente sono stati analizzati 42932 riferimenti, dei quali 42905 non sono stati considerati in quanto non soddisfacevano i criteri di inclusione appena indicati. Dunque, l'analisi, svolta secondo le 2 tipologie di meta-analisi precedentemente nominate, è stata effettuata su **32 studi**.

### Meta-analisi Standard

In generale, la **meta-analisi standard** (o **metanalisi, MA**) è una **metodologia statistica che permette di effettuare confronti diretti** tra bracci di trattamento sia sperimentali che di controllo degli studi considerati rispetto agli end-points classici. Fondamentalmente, può essere definita come una tecnica clinico-statistica che permette di "assemblare" i risultati di più trial di uno stesso trattamento in un unico risultato cumulativo dotato di un maggiore valore in termini di significatività statistica. Risulta molto utile quando ci sono incertezze nella valutazione dell'efficacia di un trattamento, a causa di:

- non univocità dei risultati dei singoli studi;
- i diversi studi sono effettuati su pochi pazienti, dunque, se vengono considerati singolarmente, risultano scarsamente affidabili.

Una **condizione necessaria** è l'omogeneità delle categorie da confrontare.

Ad ogni modo, nel campo della neuro-oncologia la standard meta-analysis, svolta per la ricerca del trattamento sul GBM, si è dimostrata meno efficace a causa delle restrizioni intrinseche dei confronti diretti tra 2 bracci di trattamento.

### Meta-analisi Network

A causa degli esiti negativi ottenuti con la meta-analisi standard, la ricerca sul trattamento del GBM è proseguita svolgendo la **network meta-analysis (NetMA)**, la quale ricopre un ruolo fondamentale quando l'obiettivo è **confrontare 3 o più trattamenti destinati alla medesima indicazione clinica**. Le **caratteristiche principali** della NetMA sono:

- inglobare in un'unica analisi tutte le evidenze disponibili;
- confrontare direttamente e indirettamente: fornisce informazioni riguardo sia confronti diretti (ad esempio A vs B) sia confronti indiretti in cui non esiste un trial clinico di confronto di un trattamento A contro un trattamento C, piuttosto esistono 1 o più studi di confronto tra A e B e 1 o più studi di confronto tra B e C.

Dunque, si nota che la NetMA supera il limite dalla meta-analisi standard, permettendo di analizzare casi in cui i trattamenti confrontabili siano 3 o più.


Una **condizione necessaria** è che tutti i trial inseriti nella rete di comparazioni abbiano lo stesso end-point di rilevazione tra tutti i diversi studi.

Ad ogni modo, tutti i confronti diretti e indiretti tra i vari trattamenti non hanno riportato un vantaggio particolarmente superiore di un trattamento specifico rispetto a tutti gli altri.

### Risultati del meta-analysis approach: verso il Cognitive Computing

Seppure la meta-analisi standard e la network meta-analysis (che ha meno limitazioni) siano 2 strumenti statistici ampiamente validati in medicina, essi **non hanno prodotto risultati statisticamente significativi per alcun trattamento**.

L'aumento delle informazioni e dei trattamenti strutturati e non strutturati relativi a tale malattia consente di poter **riconsiderare il modello di ricerca**, basandosi sull'utilizzo di strumenti diversi per provare a superare le difficoltà riscontrate nello svolgimento delle meta-analisi. A tal fine, è stata ideata una complessa **architettura cognitiva** per definire una strategia innovativa per affrontare il problema. Infatti, il **problema** fondamentale dell'approccio classico oncologico basato su meta-analisi consiste nella **rigida selezione degli studi clinici** dovuta ai criteri di inclusione e di esclusione precedentemente indicati. Invece, si suppone che l'**approccio cognitivo sia in grado di ampliare** il set di studi a disposizione, ovvero i dati disponibili dai quali attingere in modo da ottenere risultati statisticamente significativi.



**Figura 1.3:** Curva dell'approccio utilizzato in base alle risorse e alla complessità

## 1.3 Analisi del progetto

Il progetto del corso di *Cognitive Computing Systems* consiste nell'**implementazione di un sistema cognitivo per l'analisi di documenti scientifici** relativi al glioblastoma multiforme. L'obiettivo è produrre una meta-analisi che analizzi i risultati di più studi relativi al GBM, usando l'intelligenza artificiale, in particolare le tecniche di elaborazione del linguaggio naturale (NLP).

Lo svolgimento del progetto richiede un'attenta descrizione della metodologia applicata e dell'architettura del sistema proposta. La **struttura** è la seguente:

1. raccolta dei documenti scientifici;
2. individuazione delle entità e delle relazioni rilevanti;
3. creazione di un modello customizzato di NLP;
4. deploy del modello su un servizio di intelligenza artificiale per una ricerca cognitiva;
5. query personalizzate;
6. analisi statistica e interpretazione dei risultati;
7. presentazione grafica dei risultati.

Ad ogni modo, la richiesta specifica consiste nel focalizzarsi sull'implementazione del sistema cognitivo per il NLP. I **task da risolvere** sono i seguenti:

- svolgere operazioni di preprocessing che migliorino la qualità dei documenti forniti;
- ridefinire in maniera accurata le relazioni tra le entità (con il supporto degli esperti di dominio);
- introdurre nuovi vincoli (con il supporto degli esperti di dominio).

Le **tecnologie** da utilizzare per lo svolgimento sono i **servizi IBM Cloud**, in particolare:

- **IBM Watson Knowledge Studio**: permette di insegnare ad IBM Watson il linguaggio del dominio medico, attraverso un modello personalizzato in grado di identificare le entità e le relazioni degli studi clinici relativi il GBM;
- **IBM Watson Discovery**: permette di effettuare l'ingestion, normalizzare, arricchire, indirizzare e ricercare gli studi clinici, semplificando le difficoltà dovute all'analisi di grandi dataset.


Per quanto riguarda il **dataset**, le fonti da cui sono stati reperiti gli articoli sono quelle indicate in precedenza (vedi sottoparagrafo 1.2.2). In particolare, gli **articoli** sono suddivisi in 4 archivi:

- Parte 1: contiene 672 file;
- Parte 2: contiene 113 file;
- Parte 3: contiene 60 file;
- Parte 4: contiene 46 file.

Tutti gli articoli sono in **formato pdf**.

La seguente figura (1.4) riporta la **struttura complessiva del sistema** da sviluppare.

Grazie alla **collaborazione degli esperti di dominio** è possibile insegnare a IBM Watson il linguaggio del dominio medico. L'addestramento di modelli personalizzati in grado di identificare entità e relazioni di interesse, fornite dagli esperti di dominio e presenti all'interno dei documenti, permette il recupero di un maggior numero di articoli scientifici rispetto all'approccio tradizionale della meta-analisi.



**Figura 1.4:** Architettura del sistema cognitivo per il trattamento del GBM

Il seguente schema effettua un **riepilogo del progetto**:

**dataset:** articoli scientifici sul GBM divisi in Parte 1, 2, 3, 4

**obiettivo:** sviluppo di un sistema cognitivo per il trattamento del glioblastoma multiforme (GBM)

**task da risolvere:**

1. data preprocessing
2. creazione di un modello di Machine Learning per il NLP con ridefinizione delle relazioni
3. creazione di una collezione di documenti per svolgere ricerche
4. analisi dei risultati

**strumenti minimi:** IBM Watson Knowledge Studio  
IBM Watson Discovery


# Capitolo 2

## Progettazione del sistema cognitivo

### 2.1 Definizione della pipeline di lavoro

Una volta introdotto il problema e l'obiettivo del progetto del corso di *Cognitive Computing Systems* e aver descritto in maniera precisa i concetti relativi alla meta-analisi, si espone la metodologia applicata dal gruppo di lavoro per lo svolgimento del progetto.

Prima di addentrarsi all'interno dello sviluppo del sistema di calcolo cognitivo, è stato analizzato in maniera precisa il problema, in modo da definire una **pipeline di lavoro** che orientasse lo svolgimento del progetto. La seguente figura riporta le varie **fasi di sviluppo**.



**Figura 2.1:** Pipeline di lavoro

1. **Data Preprocessing:** fase in cui il dataset di articoli fornito è stato opportunamente elaborato per renderlo utilizzabile nel modo migliore all'interno della piattaforma IBM Watson; in particolare, le operazioni di preprocessing svolte riguardano l'estrazione dell'abstract di ogni articolo e la conversione di esso dal formato pdf al formato txt;
2. **Machine Learning Model for NLP:** fase in cui è stato sviluppato un modello di Machine Learning in grado di apprendere il linguaggio del dominio

medico, tale da identificare le entità e le relazioni relative gli studi clinici sul GBM;

3. **Creation of a Data Collection:** fase in cui si definisce una collezione di articoli da utilizzare per svolgere ricerche mirate sul GBM, dopo che il modello ha appreso il linguaggio di dominio;
4. **Data Visualization & Results:** fase finale in cui si effettuano alcune osservazioni e riflessioni sui risultati ottenuti dallo sviluppo del modello.

Definite le fasi di lavoro, sono stati individuati gli opportuni **tools** da usare:

- **Python Environment** per la fase di preprocessing, in particolare per la conversione degli articoli dal formato pdf a jpeg;
- **MATLAB (MathWorks)** per la fase di preprocessing, in particolare per la conversione degli abstract dal formato jpeg al formato txt;
- **Watson Knowledge Studio (WKS)** per la creazione di un modello per la comprensione del linguaggio del dominio medico;
- **Watson Discovery** per lo svolgimento di ricerche mirate in base a specifiche query.

Come detto in precedenza, il dataset di articoli è diviso in 4 archivi. A causa delle limitazioni dovute al piano Lite dei servizi IBM di cui si usufruisce, si è scelto di utilizzare come **dataset l'archivio di articoli Parte 1**, contenente in tutto 672 file (da manipolare opportunamente in fase di preprocessing, prima di caricarli su WKS).

La seguente figura riporta il **dataflow del sistema completo**, ovvero il flusso di dati tra i vari tools utilizzati per lo svolgimento del progetto. A partire dal dataset, gli articoli vengono caricati in uno script Python in un apposito ambiente per svolgere su di essi le operazioni di preprocessing atte ad estrarre la prima pagina (relativa all'abstract) e a convertirla in formato JPEG (**flow 1**); dopodiché, gli output ottenuti vengono memorizzati in una cartella di Google Drive per la condivisione di essi tra i vari componenti del gruppo di lavoro (**flow 2**). Gli articoli in formato JPEG vengono caricati in MATLAB per essere sottoposti ad una seconda fase di preprocessing per l'estrazione, mediante motore OCR, del testo presente in ciascuna immagine (**flow 3**). I file testuali così ottenuti compongono il corpus da fornire a Watson Knowledge Studio per lo sviluppo del modello di Machine Learning per il NLP (**flow 4**), dopodiché si definisce una collection in

Watson Discovery per svolgere opportune query (**flow 5**). Infine, in base ai dati utilizzati e agli output ottenuti, si svolgono opportune osservazioni sui risultati (**flow 6**).




Figura 2.2: Data-flow tra i tools

## 2.2 Data preprocessing

L'obiettivo del **Data preprocessing**, effettuato sugli articoli del dataset, è **estrarre dai files in formato .pdf la porzione di testo relativa all'abstract**, come suggerito dagli esperti di dominio, **per salvarlo in formato .txt**, al fine di ottenere una buona versione di dati testuali per la composizione del corpus da fornire al servizio di Watson Knowledge Studio per lo sviluppo di un modello che apprende il linguaggio del dominio medico. Nel presente paragrafo saranno mostrate le problematiche riscontrate nell'effettuare la conversione di formato dei files mediante l'uso di moduli Python e verrà presentato l'approccio di conversione utilizzato nell'elaborato, definendo anche due proposte per superare le limitazioni riscontrate.

L'operazione di **conversione** degli articoli è stata reputata **necessaria** a causa della loro formattazione intrinseca che conduce ad alcune problematiche. Considerando come esempio l'articolo riportato nella seguente figura, si può notare subito



che il **primo problema** è legato al fatto che gli **articoli non prevedono una sequenza lineare di frasi** unicamente separate da punteggiatura, ma consistono in paragrafi che possono essere ordinati in più colonne, annotazioni e riferimenti riportati su un lato del foglio, immagini e background di diversa colorazione, e così via.

|                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                |                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                         |
|--------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|-----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| <p>ELSEVIER journal homepage: www.elsevier.com</p>                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                             |                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                         |
| <p><b>1p/19q loss within oligodendroglioma is predictive for response to first line temozolomide but not to salvage treatment</b></p>                                                                                                                                                                                                                                                                                                                                                                                                                                          |                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                         |
| <p>Mathilde C.M. Kouwenhoven<sup>a</sup>, Johan M. Kros<sup>b</sup>, Pim J. French<sup>a</sup>, Elize M. Biemond-ter Stege<sup>a</sup>, Wilfried J. Graveland<sup>b,c</sup>, Martin J.B. Taphoorn<sup>d</sup>, Alba A. Brandes<sup>e</sup>, Martin J. van den Bent<sup>a,*</sup></p>                                                                                                                                                                                                                                                                                           |                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                         |
| <p><sup>a</sup>Department of Neuro-Oncology, Daniel den Hoed Oncology Center, P.O. Box 5201, 3008AE Rotterdam, The Netherlands<br/> <sup>b</sup>Department of Pathology, ErasmusMC Rotterdam, The Netherlands<br/> <sup>c</sup>Department of Medical Statistics, Daniel den Hoed Oncology Center, Rotterdam, The Netherlands<br/> <sup>d</sup>Department of Neurology, MC Haaglanden-Westende Hospital, The Hague, The Netherlands<br/> <sup>e</sup>Medical Oncology Department, Neurooncology Unit, Azienda Ospedale-Università-Istituto Oncologico Veneto, Padova, Italy</p> |                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                         |
| <p>ARTICLE INFO</p>                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                            | <p>ABSTRACT</p>                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                         |
| <p>Article history:<br/>Received 25 April 2006<br/>Accepted 2 May 2006<br/>Available online 17 August 2006</p>                                                                                                                                                                                                                                                                                                                                                                                                                                                                 | <p><b>Background:</b> Combined loss of 1p/19q predicts an almost 100% response rate to first line procarbazine, CCNU and vincristine chemotherapy (PCV) chemotherapy in oligodendroglial tumours. We assessed the impact of 1p and 19q loss on the outcome to first line temozolomide (TMZ) chemotherapy and to second line PCV or TMZ in progressive oligodendroglial tumours.</p>                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                     |
| <p><b>Keywords:</b><br/>Anaplastic oligodendroglioma<br/>Anaplastic oligoastrocytoma<br/>Glioma<br/>PCV<br/>Temozolomide<br/>Chemotherapy<br/>1p<br/>19q</p>                                                                                                                                                                                                                                                                                                                                                                                                                   | <p><b>Materials and methods:</b> Tumour samples from patients included in two prospective EORTC studies on first line and second line TMZ chemotherapy in recurrent oligodendroglioma were used for this study. Most patients in the first line TMZ trial received PCV at further progression. Loss of 1p and 19q was assessed on paraffin embedded tumour samples by fluorescent in situ hybridisation with locus specific probes for 1p36 and 19q13.</p> <p><b>Results:</b> Losses of 1p and 19q were mainly observed in morphologically classical oligodendrogliomas (OD). Thirteen out of 18 patients with 1p loss (72%) responded to first line temozolomide (<math>p &lt; 0.01</math>). Both response to second line salvage PCV or to second line temozolomide was limited, even in patients with combined 1p/19q loss. Patients with tumours with 1p loss treated with salvage PCV had improved PFS (<math>p &lt; 0.05</math>). More patients with 1p loss were alive at 60 and 120 months after initial surgery (<math>p &lt; 0.001</math>).</p> <p><b>Conclusion:</b> Combined 1p/19q loss is mainly observed in classical OD. Responses to first line temozolomide are strongly correlated to loss of 1p. Response to second line alkylating treatment is modest even in tumours with 1p/19q loss. For further improvement of outcome in OD novel treatments are needed.</p> |
| <p>© 2006 Elsevier Ltd. All rights reserved.</p>                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                               |                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                         |

**Figura 2.3:** Esempio di formattazione di un articolo

A causa di tale formattazione, quando si effettua il caricamento in Watson Knowledge Studio accade che il layout proprio della pagina **infi**ci la **validità del testo** riportato al suo interno. Infatti, come è possibile notare dalla seguente figura, che mostra come viene caricato in WKS l'articolo riportato superiormente come esempio, le parole e le frasi appartenenti a paragrafi, annotazioni o colonne differenti vengono concatenate, impedendo di ottenere un testo chiaro e correttamente convertito. Ad esempio, i titoli riportati in grassetto maiuscolo nell'articolo, ovvero **ARTICLE INFO** e **ABSTRACT**, nel file caricato in WKS assumono la forma di **ARTICLEINFOABSTRACT** e la stessa cosa accade anche per altre frasi o parole presenti in questo articolo di esempio o altri articoli appartenenti al dataset.




Figura 2.4: Visualizzazione del documento in Watson Knowledge Studio

Un **altro problema** da non sottovalutare durante la fase di conversione è legato al fatto che i vari articoli proposti **non prevedono lo stesso pattern (o layout di pagina)**. In altre parole, non tutti seguono uno stesso schema di impaginazione, difatti ci sono articoli che sono scritti su 2 colonne per pagina, altri che prevedono 1 sola colonna, alcuni che presentano molte immagini o tabelle centrate o poste su un lato, altri con annotazioni e intestazioni, e così via. Tale problematica evidenzia l'impossibilità di utilizzare un unico pattern per tutti gli articoli per matchare la porzione di testo riguardante l'abstract, in quanto esso potrebbe trovarsi, per ogni articolo, in posizioni o formattazioni differenti.

Tenendo conto delle problematiche appena riportate, sono state valutate più possibilità per svolgere la fase di preprocessing nel migliore dei modi, cercando di ottenere una buona qualità del testo estratto. A seguire, vengono definite le soluzioni proposte per la fase di preprocessing, focalizzando l'attenzione su quella adottata per lo svolgimento del progetto.


### 2.2.1 Conversione attraverso i moduli Python

Una prima soluzione per effettuare la conversione dal formato .pdf a .txt consiste nell'**utilizzo di opportuni moduli Python** specificamente implementati per svolgere la suddetta conversione. In particolare, sono stati utilizzati più moduli per lo svolgimento della conversione, ma, dopo una fase di test di ognuno di essi,

tale modalità è stata **scartata**, in quanto la conversione con tali moduli porta a 2 problematiche particolari:

1. i testi estratti e convertiti in .txt presentano gli stessi problemi degli articoli, una volta caricati in Watson Knowledge Studio, relativi alla formattazione e al layout del file .pdf originario;
2. seppure il layout della pagina venga quasi del tutto rispettato, vi sono alcuni caratteri che non vengono riconosciuti come standard, per cui vengono sostituiti con il carattere <?> (tale problematica si presenta anche se si specifica di utilizzare lo standard UTF-8).

La seguente figura evidenzia alcune porzioni di testo in cui sono evidenti i problemi appena descritti.



**Figura 2.5:** Evidenza dei problemi riscontrati a seguito della conversione con moduli Python

Dunque, seppure tale soluzione abbia il **vantaggio** di essere facilmente adottabile, in quanto richiede unicamente l'installazione dei moduli necessari (operazione che viene facilitata attraverso il comando `pip` di Python) e della scrittura di un semplice script in cui si adoperano i metodi di tali moduli, essa presenta lo **svantaggio** di fornire delle conversioni poco accurate con problemi visibili da non sottovalutare.


## 2.2.2 Conversione mediante motore OCR

Dovendo estrarre del testo da files in diverse versioni di formato .pdf, senza poter sfruttare moduli python che, ammesso siano disponibili, riescano ad estrarre cor-

rettamente, da file albero COS (“Carousel” Object Structure), gli oggetti testuali formattati secondo le esigenze progettuali, la proposta di risoluzione del problema prevede l’utilizzo dell’**elaborazione di segnali multimediali**. Dunque, la seconda soluzione proposta, che è anche quella **adottata per lo svolgimento del progetto**, prevede l’utilizzo del **motore OCR** in ambiente MATLAB. OCR (Optical Character Recognition) è un motore per il riconoscimento ottico dei caratteri, una tecnologia che permette di convertire tipi diversi di documenti in dati modificabili e ricercabili. Infatti, il motore è in grado di riconoscere i caratteri presenti all’interno di un’immagine e di unirli per formare parole con cui poi creare delle frasi, permettendo di ricostruire in maniera accurata il testo completo presente nell’immagine fornita come input. Esempi applicativi del motore OCR sono:

- a: rilevazione e riconoscimento automatico del testo nelle immagini naturali;
- b: riconoscimento del testo usando OCR;
- c: digit classification usando le features HOG.

Per ulteriori approfondimenti sul motore OCR, si rimanda alla documentazione ufficiale MathWorks di MATLAB. Tale motore è scaricabile come Toolbox dal menu *Add-Ons* dell’interfaccia di MATLAB.



**Figura 2.6:** Esempi applicativi di OCR

La soluzione proposta si divide in 4 step principali:

1. conversione dei file dal formato .pdf al formato .jpeg;
2. semantic segmentation;
3. creazione di etichette e segmentazione di pagina;
4. alimentazione del motore OCR con input immagine per l’estrazione del testo.

## Conversione da formato pdf a jpeg

La prima operazione da svolgere consiste nel **convertire gli articoli dal formato .pdf al formato immagine .jpeg**. Come accennato in precedenza, l'obiettivo finale è estrarre da ogni articolo il testo relativo all'abstract, per questo, a partire dall'ipotesi che, almeno per la maggior parte degli articoli, l'abstract sia contenuto nella prima pagina di ognuno di essi, è stata effettuata unicamente la conversione in file immagine della pagina numero 1 di ciascuno di essi.

La conversione in file immagine è stata effettuata in **ambiente Python**, attraverso il modulo **pdf2image**, implementando il seguente script. Definiti, rispettivamente, i path della directory da cui prelevare i file pdf da convertire e di quella dove salvare gli output immagine, si definisce una lista contenente il nome completo di ciascun articolo. Fatto ciò, si esegue la conversione, utilizzando i metodi del modulo citato. In particolare:

- `convert_from_path()`: riceve come argomenti di input il file da convertire, la risoluzione e il range di pagine da convertire (indicando `first_page=1` e `last_page=1` si effettua la conversione solo della prima pagina, in quanto è l'unica realmente di interesse per gli obiettivi preposti, in modo da evitare la conversione dell'intero articolo ogni volta che provoca un notevole dispendio di risorse inutile);
- `save()`: permette di salvare in formato .jpeg le immagini convertite con il precedente metodo.

```
1 #Requires: pip install pdf2image
2
3 from pdf2image import convert_from_path
4 import os
5
6 #Directory from where loading pdf files that have been converted
7 d = r"PATH_TO_PDF_FILES"
8
9 #Creation of the directory where saving the output files (jpeg files)
10 new_d = r"PATH_TO_OUTPUT_FILES"
11 os.makedirs(new_d, exist_ok=True)
12
13 #Obtaining a path list of the pdf files to convert
14 path_list = []
15 for path in os.listdir(d):
16     full_path = os.path.join(d, path)
17     if os.path.isfile(full_path):
```

```
18     path_list.append(full_path)
19
20 #Conversion and output saving
21 for file in path_list:
22     print(file)
23     pages = convert_from_path(file, 700, first_page=1, last_page=1)
24     new_path = (os.path.splitext(os.path.basename(file))[0] + ".jpeg")
25     print(new_path)
26     output_file = new_d + '\\\\' + new_path
27     print(output_file)
28     pages[0].save(output_file, 'JPEG')
```

La conversione svolta con lo script riportato ha evidenziato ulteriori problematiche interne degli articoli pdf forniti come dataset che non hanno permesso una corretta conversione, portando inevitabilmente a doverli scartare. Dunque, questa prima fase di preprocessing è stata effettuata a partire da 672 articoli e ha prodotto come **output 324 file .jpeg** da fornire come input alla seconda parte del preprocessing.

## Semantic Segmentation

Poiché i dati d'interesse per l'analisi mediante WKS sono da ricercarsi principalmente nelle sezioni testuali di ciascuna pagina componente i files, l'attenzione verrà posta sull'estrazione di tali regioni d'interesse tralasciando quelle relative alle immagini e tabelle in essi contenute. Un'ulteriore estrazione avanzata, soprattutto per i dati riportati nelle tabelle, dovrà essere considerata in futuro qualora la scelta delle entità e le relazioni giustificate lo richiedano nella fase di annotazione. Le proposte per la risoluzione del problema prevedono due approcci: uno basato sui dati (data-driven) e l'altro basato su modello (model-based). Dei due approcci, quello data-driven risulta essere più di tendenza ed in prospettiva promette migliori performance anche se notevolmente time e resource consuming.

Entrambi gli approcci hanno dei passi in comune:

- Segmentare le regioni di testo nelle pagine
- Sequenziare le sezioni secondo un ordine lessicografico coerente col layout di pagina
- Riconoscere il testo contenuto nelle regioni mediante OCR

L'approccio basato su modello è, nella fase iniziale, complementare a quello basato sui dati per semi-automatizzare la creazione di etichette che andranno a formare il set per l'addestramento, validazione e test di una rete neurale (apprendimento supervisionato).



Per ridurre al minimo sforzo la creazione di etichette che devono essere verificate, il trasferimento di conoscenza (transfer learning) da reti quali VGG16 potrà essere tenuto in considerazione nella fase di sviluppo.

### **Creazione di etichette e segmentazione di pagina**

Prima di esporre i passi per la segmentazione di pagina è bene effettuare alcune osservazioni:

- La scelta empirica dell'elemento strutturante, per le operazioni morfologiche su immagini in scala di grigio, è sensibile:
  - alla qualità di conversione in formato .jpeg (una conversione a bassa risoluzione comporta del rumore nelle immagini che sarà amplificato dalle operazioni morfologiche necessarie all'individuazione delle sezioni);
  - alla variazione di scala (dimensione) dei caratteri contenuti nell'immagine;
- Le pagine devono essere convertite in immagini ad alta risoluzione dove per alta s'intende quanto basta all'OCR (Optical Character Recognition) per non cadere in ambiguità sul riconoscimento di un carattere piuttosto che un altro;
- Le pagine presentano una varietà di sezioni localizzate in differenti posizioni. Per citare alcune sezioni: intestazione, piè di pagina, paragrafi su più colonne nella stessa pagina;
- Alcuni testi risiedono su sfondo a colori che trasformato su scala di grigio tende a confondere l'OCR nel riconoscimento del carattere.

Considerando le osservazioni precedenti, la creazione di etichette prevede i seguenti passi:

- Rimozione delle zone uniformi che costituiscono lo sfondo testuale a colori;
- Conversione di ciascuna pagina su scala di grigi;
- Uniformare la scala (dimensione) dei caratteri e se necessario effettuare enhancement per facilitare l'OCR nel riconoscimento dei caratteri;

- Fissare in maniera empirica e su un campione significativo d'immagini l'elemento strutturante, per le operazioni di dilatazione del testo, in base alla scala dei caratteri e "rumore" dovuto alla conversione in immagine (tale "rumore", insignificante per la percezione della visione umana, è dovuto agli standard di compressione che prevedono una fase di trasformazione DCT a blocchi, *quantizzazione* e codifica entropica);
- Segmentazione dell'immagine per individuare le sezioni attraverso una maschera binaria/etichetta: operazione morfologica di dilatazione e sogliatura;



**Figura 2.7:** Pagina di testo e rispettiva maschera/etichetta

- Controllo di qualità mediante ispezione visiva a supporto delle successive operazioni di addestramento della rete neurale che dovrà segmentare le pagine in maniera automatica.

## Motore OCR per la conversione da formato jpeg a testuale

Il seguente codice MATLAB, utilizzato per la conversione in formato .txt, mostra i passi per l'estrazione delle regioni contenenti il testo, inoltre, al passo 3.1 ritroviamo la regolarizzazione dello stesso testo riconosciuto mediante OCR. Per regolarizzazione s'intende, nel nostro caso, il salvataggio di simboli e punteggiatura presenti rimuovendo esclusivamente il punto di fine periodo. Ulteriore normalizzazione riguarda la sostituzione del punto delle cifre decimali con la virgola, in quanto WKS potrebbe riconoscere il punto come fine periodo. La scelta di tale strategia è dettata principalmente dal voler permettere un raggruppamento semantico



del testo da parte di WKS tale da consentire il maggior numero di annotazioni per le relazioni. WKS attualmente non rende possibile stabilire relazioni tra entità appartenenti a periodi differenti.

Il codice seguente necessita di miglioramenti secondo le linee guida che sono state presentate precedentemente e nel caso si volesse proseguire con un approccio model-based. Si precisa che tale codice fornisce un'idea per la segmentazione del testo presente nell'immagine. Le operazioni da eseguire, con approccio model-based, per ottenere un risultato soddisfacente sono in numero maggiore.

```
1 clear;
2 close all;
3 clc;
4
5 % Acquisizione dei files .jpeg da cartella condivisa su googleDrive
6 mylist = ls;
7
8 for i = 3:length(mylist)-2           % esclusione ., .. , desktop.ini
9
10     % STEP 1. Acquisizione
11
12     % Rimozione caratteri bianchi dai nomi dei files
13     fileName = deblank(mylist(i,:))
14
15     % Acquisizione file
16     im = imread(fileName);
17
18     % Conversione immagine su scala di grigi
19     x = rgb2gray(im);
20
21     % Eventuale visualizzazione
22     imshow(x, []);
23     %pause();
24
25     % STEP 2. Segmentazione pagina in regioni testuali
26
27     % Scelta empirica dell'elemento strutturante
28     y = imopen(x, strel('disk', 50));
29
30     % Sogliatura
31     binaryImage = y < 255;
32
33     % Eventuale visualizzazione della maschera binaria
34     imshow(binaryImage, []);
35     %pause();
```

```
36
37 % Estrazione regioni d'interesse
38 [labeledImage, numRegions] = bwlabel(binaryImage);
39
40 % STEP 3. Riconoscimento testo mediante OCR
41 for k = 1 : numRegions
42
43     % Selezione regione d'interesse
44     thisRegion = uint8(ismember(labeledImage, k));
45     % Selezione segmento d'immagine
46     txt = thisRegion .* x;
47     % Ripristino sfondo bianco, se nero confonde l'OCR
48     thisRegion = (thisRegion + 255).*(1 - thisRegion);
49
50     % Pagina con la sola regione d'interesse
51     txt = txt + thisRegion;
52
53     % OCR per la conversione in text
54     ocrResults = ocr(txt);
55
56     % STEP 3.1 Personalizzazione nella regolazzazione del testo
57     % (N.B. E' possibile superare tutte le seguenti
58     % problematiche con approccio data-driven piuttosto che
59     % model-based)
60
61     %str = erasePunctuation(str)
62     % Tale istruzione e' commentata poiche'permette la
63     % rimozione di tutta la punteggiatura; col seguente
64     % codice si cerca di conservare quanti piu' simboli possibile
65     % congiungendo i periodi(eliminando i punti di fine periodo)
66
67     % Rimozione caratteri ambigui tra due digit es. 34&45 (la
68     % scelta sara' motivata nel seguito dopo aver esposto
69     % le problematiche);
70     str = replace(ocrResults.Text, {'-', '/', '\', '\'', '(', ')', ',', '.', '
71     '-', ':', ';', '&', '?', '^'}, ' ');
72
73     % Rimozione del solo punto
74     str = replace(ocrResults.Text, {'.'}, '');
75     % Estrazione digit senza punto
76     ex1 = regexp(str, '[+-]?\d+(\.\d+)?', 'match')
77     % Estrazione cifre decimali
78     ex2 = regexp(ocrResults.Text, '[+-]?\d+(\.\d+)?', 'match')
79     % Per non confondere la fine di un periodo in WKS
```

```
79     ex2 = replace(ex2, '.', ',')
80     % Ripristino cifre decimali con virgola anziché punto
81     results = replace(str, ex1, ex2);
82     % Salvataggio in append di tutte le regioni riconosciute
83     writematrix(results, fileName(1:end-5), 'WriteMode', 'append')
84
85     % Eventuale visualizzazione
86     %figure; imshow(txt, []);
87     %pause();
88     end
89 end
```

Per quel che riguarda il numero di articoli oggetto di conversione in formato testo, su un totale di 324 in formato .jpeg solo 279 sono stati caricati su WKS poichè l'OCR può commettere errori d'interpretazione di caratteri che bloccano la successiva elaborazione automatica di sostituzione del punto con la virgola per le cifre decimali. Per ovviare a tale problema bisognerebbe conservare il punto per le cifre decimali oppure prediligere l'approccio data-driven.

### 2.2.3 Conversione mediante approccio data-model

L'approccio basato su modello prevede la scelta di key points, in ciascun segmento, per tratteggiare una geometria che li colleghi col fine di sequenziare, mediante OCR, i segmenti nell'ordine corretto. Nel nostro caso un key point può essere la coordinata in termini di ascissa ed ordinata del punto più in alto sulla sinistra in ciascun segmento oppure il centroide del segmento. Ad esempio, sulla piattaforma MATLAB, il toolbox per le elaborazioni delle immagini fornisce funzioni quali `props = regionprops(labeledImage, 'Centroid')` per il calcolo del centroide.

Fissato il tipo di key point, si calcola la distanza euclidea tra ciascuna coppia di punti (per ridurre la complessità è possibile ottimizzare il codice con algoritmi di ricerca operativa) e si sequenziano i segmenti, mediante OCR, dall'alto verso il basso e da sinistra verso destra prediligendo i segmenti più vicini in termini di distanza euclidea.

Per una migliore comprensione è possibile usare come esempio la segmentazione di parti di un volto. Esso presenterà due occhi, un naso ed una bocca. Si potrebbe scegliere di sequenziare prima l'occhio sinistro, poi il destro ed infine la bocca. Sfruttando la distanza euclidea, i punti chiave e l'ordine dall'alto verso il basso e da sinistra verso destra la sequenza diventerà: occhio sinistro, occhio destro, naso (la distanza occhio destro-naso è minore rispetto a quella occhio destro-bocca) e

bocca. Per quel che riguarda il sequenziamento dei segmenti di testo, non avendo fisso il layout (a differenza della posizione occhi, naso e bocca), è necessario estrarre i pattern ricorrenti di layout per correggere quelli che non rispettano la scelta di key points, ordinamento e distanza euclidea per un sequenziamento corretto.



**Figura 2.8:** Sequenziamento su volto e regioni della maschera binaria

Per la maschera del testo si è riportato un esempio di risultato di sequenziamento corretto delle regioni senza ulteriori collegamenti poiché è possibile apportare delle ottimizzazioni all'algoritmo e ridurne la complessità computazionale.

## 2.2.4 Conversione mediante approccio data-driven


Per quel che riguarda l'approccio basato sui dati è necessario un insieme di etichette per poter addestrare la rete con metodo supervisionato. Le etichette possono essere maschere binarie, in tal caso si avrà una rete in grado di segmentare il testo in maniera automatica, oppure etichette multidimensionali di cui è implicito un sequenziamento. Nell'immagine seguente a ciascun colore corrisponde una sotto etichetta: ad esempio, il giallo potrebbe individuare un paragrafo centrale e di conseguenza in tale regione ritroveremo un numero corrispondente.



**Figura 2.9:** Maschera multidimensionale con segmentazione implicita delle regioni

La rete neurale può essere creata da zero oppure mediante trasferimento della conoscenza. I passi preliminari da eseguire per ottenere buone performance sono i seguenti:

- Stabilire una metrica per valutare la metodologia di apprendimento profondo (si parla di deep learning poiché tra lo strato di input e quello di output ci sono un numero sufficientemente grande di strati hidden che si riducono come a formare una piramide, in questo caso essendo apprendimento supervisionato gli ultimi strati effettuano una decisione);
- Il dataset deve essere opportunamente suddiviso in training, validation e test;
- Bisogna ricercare una “buona” architettura di rete basata su strati CNN usando SGD e backpropagation;
- Sfruttare reti pre-addestrate come VGG16.



**Figura 2.10:** Diagramma a blocchi esemplificativo

### Cosa misurare? Cross entropy

- Losses and regularization: towards the empirical risk minimization;

$$\underset{\theta}{\operatorname{argmin}} \left[ \frac{1}{N} \sum_{i=1}^N L(f_{\theta}(x_i) - y_i) + \lambda R(\theta) \right]$$

- Cross entropy function;

$$H(p, q) = - \sum_{i=1}^2 p(i) \log(q(i)) = - (1 - p) \log(1 - q) - p \log(q)$$

- Early stopping to prevent overfitting;

$$J(T, W) = -\frac{1}{N_T} \sum_{n=1}^{N_T} [y_n \log(\hat{y}_n) + (1 - y_n) \log(1 - \hat{y}_n)], \hat{y}_n = g(\underline{\mathbf{w}} \cdot \underline{\mathbf{x}}_n)$$

### Come procedere nell'addestramento? Semantic Segmentation

1. Si fissa un validation set per ottenere migliori risultati nella regolazione degli iperparametri;
2. È possibile utilizzare la random serch piuttosto che una regular grid;
3. Per la discesa stocastica del gradiente (SGD) è possibile selezionare mini-batches selezionati in maniera random e disgiunti, dopo ciascuna epoca è possibile effettuare shuffle;

$$\theta^{new} = \theta - \alpha_t \left[ \frac{1}{B_k} \sum_{i \in I} \left[ \frac{d}{d\theta} L(f_{\theta}(x_i) - y_i) \right] + \frac{B_k}{N} \lambda \frac{d}{d\theta} R(\theta) \right]$$

4. Per velocizzare il processo di apprendimento è possibile normalizzare i batch;
5. Valutare l'uso del drop-out;
6. Necessità di utilizzare upsampling per ottenere in output una maschera della stessa dimensione dell'immagine di partenza. Poiché la rete ha operato sull'immagine come un encoder (conv + BN + ReLU + max pooling) è necessario usare un decoder (upsampling + conv + BN + ReLU) per ristabilire la dimensione della maschera.

### Osservazioni

- Anche se i dati sono completi e vari, la rete può essere soggetta a specializzazione sui dati (overfitting) pertanto bisogna porre attenzione al punto in cui l'average loss inizia a deteriorare.
- L'apprendimento profondo richiede architetture ad alta capacità computazionale (acceleratori computazionali o GPU) per ridurre il tempo di apprendimento.
- Al termine della corretta segmentazione semantica del testo è possibile far agire l'OCR per riconoscere il testo nelle regioni d'interesse.

### 2.2.5 Risultati della fase di preprocessing

I files testuali ottenuti, col codice proposto a scopo dimostrativo, presentano segmenti convertiti in un ordine non sempre corretto. Inoltre, alcuni abstract non sono presenti nella prima pagina del file .pdf, pertanto non è possibile ritrovarlo nella conversione finale. In più, alcuni testi giacciono su sfondi colorati che confondono l'OCR nell'interpretazione dei caratteri. La risoluzione di tali problematiche è stata mostrata nei paragrafi precedenti. Il **dataset finale consta di 279 abstract di articoli in formato testuale**.

## 2.3 Creazione del modello in Watson Knowledge Studio

Una volta terminata la fase di preprocessing degli articoli, il passo successivo consiste nel configurare Watson Knowledge Studio e nel fornirgli gli abstract ottenuti in formato testuale per addestrare un modello di Machine Learning in grado di comprendere il linguaggio del dominio medico relativo al glioblastoma multiforme.

### 2.3.1 Definizione del type system

Configurare lo spazio di lavoro in Watson Knowledge Studio significa **definire il sistema tipo (type system)**, ovvero definire gli assets di interesse per il sistema. Tali assets sono **le entità e le relazioni** stabilite in fase di analisi dagli esperti di dominio.

#### Entità

Per quanto concerne le **entità**, gli esperti di dominio hanno individuato 15 Entity Types, ognuno dei quali ha un numero variabile di sottotipi. Un punto cruciale è stato quello di **introdurre nuovi parametri e vincoli** che permettessero di ampliare il set di documenti da poter considerare, rispetto a quelli ottenuti dalla meta-analisi svolta in passato. Infatti, come detto in precedenza (vedi paragrafo 1.2.2), gli end-points (o parametri) della ricerca oncologica sono:

- Overall Survival (OS);
- Progression Free Survival (PFS);
- Overall Response Rate (ORR).

Per allargare i vincoli, in aggiunta ai 3 citati end-points, sono stati **introdotti i seguenti parametri**, secondo lo studio svolto dall'esperto di dominio:

- Karnofsky Performance Status (KPS);
- Objective Response Rate (ORR);
- Net Survival Rate (o Relative Survival);
- 1-year survival rate;
- 5-year survival rate;
- Palliative Care Quality of Life Instrument (PQLI);
- Number Needed to Treat (NNT).

Tali parametri sono stati considerati degli opportuni sottotipi dell'entity type *Response to therapy*, la quale è l'entità che riguarda i parametri con cui si misura la risposta del paziente ad un determinato trattamento, in termini di end-points noti della ricerca. La seguente tabella riporta uno **schema riepilogativo**.

| N° | Entity Type                       | Entity Subtypes                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                |
|----|-----------------------------------|------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| 1  | <b>Glioblastoma</b>               | Glioblastoma, GBM, Glial tumor, Glial neoplasm, Malignant glioma, Recurrent malignant glioma, Progressive malignant glioma, Diffuse oligodendroglioma, Diffuse astrocytoma, Anaplastic oligodendroglioma, Anaplastic astrocytoma, High grade glioma, HGG, Progressive Glioblastoma, Recurrent Glioblastoma, Relapsing Glioblastoma, Residual Glioblastoma, WHO grade IV glioma                                                                                                                                                                                                                                                                                                                                                                 |
| 2  | <b>Molecular Classification</b>   | Deletion, Codeletion, Mutation, Amplification, 1p/19q codeletion, IDH1 or IDH2 mutation, TERT, EGFR, MDM4, CDKN2A/B, CCND2, MDM2, CDK4, TP53, NF1, RB1, CCND1, PDGFRA, CDK6, NF2, MYC, MET, MYB, BRAF, MYBL1, FGFR1, MGMT, MGMT status, PTEN, ATRT, Peroxisome proliferator-activated receptor gamma                                                                                                                                                                                                                                                                                                                                                                                                                                           |
| 3  | <b>Trial</b>                      | Clinical trial registry, Registry, Phase I, Phase II, Phase III, Study design, Open-label, Exclusion criteria, Inclusion criteria                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                              |
| 4  | <b>Therapy</b>                    | Chemotherapy, Target therapy, Vaccine therapy, Immunotherapy, Laser therapy, Radiotherapy, Surgery                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                             |
| 5  | <b>Chemotherapy</b>               | Nimustine, Epirubicina, Docetaxel, Ranimustine (MCNU), RH-endostatin, Fotemustine, Topotecan, Paclitaxel, Gemcitabina, Taxanes, Procarbazine, Temozolomide, Irinotecan (cpt-11), Cisplatin, Nitrosurea, Temoðar, Temodal, Tmz-poh, Carboplatin, Lomustine, Vincristine, Carmustine, Verubulin, Etoposide, Cyclophosphamide, Ifosfamide, Teniposide, Neo-212, Alkylating agent, Interferon, Rh-es, recombinant human endostatin, Convention-enhanced delivery, CED, Gliadel wafers, Carmustine wafers, Chemotherapy delivery, Intravenous delivery, Intrarterial delivery                                                                                                                                                                       |
| 6  | <b>Target Therapy</b>             | Anti-VEGF, Bevacizumab, Anti VEGFR, Sorafenib, Anti-EGFR, Erlotinib, HIV protease inhibitors, Ritonavir, Lopinavir, Regorafenib, Ramucirumab, Depatuximab, proteasome inhibitor, Marizomib, Apatinib, Pazopanib, Cediranib, Veliparib, Olaparib, PARP-inhibitors, BGJ398, IDH1 inhibitors, IDH2 inhibitors, AG-221, AG120, AG-881                                                                                                                                                                                                                                                                                                                                                                                                              |
| 7  | <b>Vaccine Therapy</b>            | DCVax-L, DC Vaccine therapy, Survivax, SurVaxM, Heat-Shock-protein peptide complex-96                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                          |
| 8  | <b>Immunotherapy</b>              | Ipilimumab, Pembrolizumab, Nivolumab, Durvalumab, Tremelimumab, Anti-PD-1, Anti-PDL-1, Anti-CTLA-4                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                             |
| 9  | <b>Laser Therapy</b>              | LITT, Laser Interstitial Thermal Therapy, Fiber Optic Laser-Emitting Catheter                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                  |
| 10 | <b>Radiotherapy</b>               | Radiation therapy, Irradiation, Re-irradiation, Gamma Knife, Fractioned radiation therapy, Unfractionated radiation therapy, Stereotactic radiosurgery, Intensity-modulated radiation therapy, IMRT, Image-guided radiation therapy, IGRT, Volumetric modulated arc therapy, VMAT, Tumor Treating Fields, TTFIELDS, NOVO/TTF, 3D conformal radiation therapy, 3DCRT                                                                                                                                                                                                                                                                                                                                                                            |
| 11 | <b>Surgery</b>                    | Biopsy, Stereotactic neurosurgery, Neuronavigation, Inoperable, Operable, Gross total tumor resection, Complete tumor resection, Partial resection, Residual tumor, Transcortical approach, Transfrontal approach, Trans superioriparietal approach, Transylvian approach, VP shunt o ventriculoperitoneal shunt, Interemisphere middle line approach, Micro surgical techniques, Maximal surgical resection                                                                                                                                                                                                                                                                                                                                   |
| 12 | <b>Magnetic Resonance Imaging</b> | Enhancement, Contrast-enhancement, Delayed contrast extravasation MRI, Treatment Response Assessment Maps, TRAMS, Perfusion imaging, Dynamic Susceptibility Contrast-enhanced, DSC, Dynamic Contrast-Enhanced, DCE, Susceptibility Weighted Imaging                                                                                                                                                                                                                                                                                                                                                                                                                                                                                            |
| 13 | <b>Response to therapy</b>        | Survival, Overall survival, OS, Progression free survival, PFS, Performance status, PS, Karnofsky Performance status, KPS, Life quality, Objective response rate, ORR, Disease-Free Survival (DFS), Net Survival Rate, Relative Survival, 1-year survival rate, 5-year survival rate, Palliative Care Quality of Life Instrument, PQLI, Number needed to threat (NNT)                                                                                                                                                                                                                                                                                                                                                                          |
| 14 | <b>Adverse effect</b>             | Collateral effect, Adverse reaction, Secondary reaction, Dosage, Toxicity, Efficacy, Tolerance, Safety, Nausea, Diarrhea, Decreased appetite, Vomiting, Dizziness, Palpitation, Fatigue, Neutropenia, Lymphocytopenia, Elevated aminotransferase, Leukopenia, Hand-foot syndrome, Skin rash, Hyponatremia, Dysphagia, Hypertriglyceridemia, Hypercholesterolemia, Thrombocytopenia, Abdominal pain, Back pain, Joint pain, Hypofosfatemia, Hyperglycemia, Hypertension, Colon perforation, Distension, Elevated lipase, Venous thromboembolism, Blood pressure, Cerebral hemorrhage, Hematologic toxicity, High blood pressure, Intestinal perforation, Infection, Skin reactions, Neurocognitive deterioration, Gastrointestinal side effects |
| 15 | <b>Response Assessment</b>        | Progression, Progressive disease, PD, True progression, Regression, Complete response, RC, Partial response, RP, Stable disease, SD, Pseudoprogression, Pseudoreponse, Radionecrosis, Cerebral radiation necrosis, Response assessment in neuro-oncology, RANO criteria, iRANO criteria                                                                                                                                                                                                                                                                                                                                                                                                                                                        |

**Figura 2.11:** Schema riepilogativo delle entità individuate



Attraverso la sezione *Assets* di Watson Knowledge Studio, è possibile inserire tali entità. La seguente schermata riporta un piccolo estratto delle entità inserite (in totale 15).

| <input type="checkbox"/> | Entity Type Name | Roles            | Subtypes                                                      | Action                                      |
|--------------------------|------------------|------------------|---------------------------------------------------------------|---------------------------------------------|
| <input type="checkbox"/> | Therapy          | Therapy          | Chemotherapy<br>Target_therapy<br><a href="#">Show all...</a> | <a href="#">Edit</a> <a href="#">Delete</a> |
| <input type="checkbox"/> | Glioblastoma     | Glioblastoma     | Glial_tumor<br>Glial_neoplasm<br><a href="#">Show all...</a>  | <a href="#">Edit</a> <a href="#">Delete</a> |
| <input type="checkbox"/> | Vaccine_Therapy  | Vaccine_Therapy  | DCVax_L                                                       | <a href="#">Edit</a> <a href="#">Delete</a> |
| Items per page: 10       |                  | 1-10 of 15 items |                                                               | 1 of 2 pages                                |

**Figura 2.12:** Estratto delle entità inserite in WKS

## Relazioni

Definite le entità, il passo successivo consiste nello stabilire le **relazioni tra di esse**. Grazie alle operazioni di preprocessing descritte in precedenza con cui si è rimossa la punteggiatura di fine periodo, è possibile superare i limiti di WKS presenti in fase di annotation che non permettono di unire in una relazione entità appartenenti a periodi differenti. Con l'elaborazione effettuata, rispetto a soluzioni passate del progetto, risulta possibile dare un peso diverso alle relazioni, le quali, non solo sono state definite in maniera più dettagliata a seguito di più incontri con gli esperti di dominio, ma possono anche essere annotate per migliorare l'addestramento del modello. La seguente tabella riporta uno **schema riepilogativo**.

|                                           |                                                  |                                       |
|-------------------------------------------|--------------------------------------------------|---------------------------------------|
| glioblastoma – chemotherapy               | target therapy – response to therapy             | immunotherapy – response to therapy   |
| glioblastoma – target therapy             | target therapy - response assessment             | immunotherapy – response assessment   |
| glioblastoma - radiotherapy               | target therapy - adverse effect                  | immunotherapy – adverse effect        |
| glioblastoma – surgery                    | radiotherapy- response assessment                | laser therapy – response to therapy   |
| glioblastoma – immunotherapy              | radiotherapy – adverse effect                    | laser therapy – response assessment   |
| glioblastoma – laser therapy              | radiotherapy – response to therapy               | laser therapy – adverse effect        |
| glioblastoma – vaccine therapy            | surgery- response assessment                     | vaccine therapy – response to therapy |
| glioblastoma - magnetic resonance imaging | surgery- adverse effect                          | vaccine therapy – response assessment |
| therapy – trial                           | surgery – response to therapy                    | vaccine therapy – adverse effect      |
| chemotherapy - response to therapy        | magnetic resonance imaging – response assessment |                                       |
| chemotherapy – response assessment        |                                                  |                                       |
| chemotherapy – adverse effect             |                                                  |                                       |

**Figura 2.13:** Schema riepilogativo delle relazioni individuate tra le entità

Attraverso la sezione *Relation Types* di *Assets*, è possibile inserire in Watson Knowledge Studio le relazioni individuate dagli esperti di dominio. La seguente figura riporta un estratto di quanto inserito in WKS.

| Relation Type                                            | First Entity Type / Role | Second Entity Type / Role | Action                                      |
|----------------------------------------------------------|--------------------------|---------------------------|---------------------------------------------|
| immunotherapy_adverse_effect                             | Immunotherapy            | Adverse_Effect            | <a href="#">Edit</a> <a href="#">Delete</a> |
| immunotherapy_response_assessment                        | Immunotherapy            | Response_Assessment       | <a href="#">Edit</a> <a href="#">Delete</a> |
| laser_therapy_response_to_therapy                        | Laser_Therapy            | Response_to_therapy       | <a href="#">Edit</a> <a href="#">Delete</a> |
| surgery_response_assessment                              | Surgery                  | Response_Assessment       | <a href="#">Edit</a> <a href="#">Delete</a> |
| target_therapy_adverse_effect                            | Target_Therapy           | Adverse_Effect            | <a href="#">Edit</a> <a href="#">Delete</a> |
| Items per page: 10 ▾ 1-10 of 32 items 1 ▾ of 4 pages ◀ ▶ |                          |                           |                                             |

Figura 2.14: Estratto delle relazioni inserite in WKS

## Dizionario

Prima di effettuare l'addestramento del modello, è stato **definito un dizionario** per svolgere una fase di **pre-annotation** che permettesse di annotare automaticamente tutti i termini riportati in esso con le rispettive entità definite. Il dizionario è stato sviluppato a partire dallo schema *Entity type - Entity Subtypes* (vedi figura 2.11), in modo tale che:

- *Entity Subtypes*: rappresenta l'insieme dei possibili termini con cui l'entità relativa può presentarsi nel testo;
- *Entity Type*: rappresenta l'entità da associare al rispettivo termine (o sotto-tipo) individuato nel testo.

La seguente figura riporta un estratto del dizionario implementato in WKS.

Create Dictionary

Trial 9

Chemotherapy 38

Response to the... 13

Molecular classi... 32

Target therapy 27

Radiotherapy 11

Surgery 18

Magnetic Reson... 9

Adverse Effect 45

Trial

Language: English | 9 entries

Entity type: Trial

Rule class: None

Add Entry

Upload

Download

Enter text to filter

| <input type="checkbox"/> | Lem...             | Surface Forms      | Part ... | Action                                      |
|--------------------------|--------------------|--------------------|----------|---------------------------------------------|
| <input type="checkbox"/> | registry           | registry           | Unknown  | <a href="#">Edit</a> <a href="#">Delete</a> |
| <input type="checkbox"/> | inclusion criteria | inclusion criteria | Unknown  | <a href="#">Edit</a> <a href="#">Delete</a> |
| <input type="checkbox"/> | exclusion criteria | exclusion criteria | Unknown  | <a href="#">Edit</a> <a href="#">Delete</a> |

Items per page: 100 ▾ 1-9 of 9 items 1 ▾ of 1 pages ◀ ▶

Figura 2.15: Estratto del dizionario implementato in WKS per la pre-annotation

## 2.3.2 Machine Learning Model

Con il termine Machine Learning si intende l'autoapprendimento di una macchina, ovvero la capacità di apprendere dai dati, i quali, strutturati o non strutturati, al giorno d'oggi rappresentano la più grande risorsa. Quindi, il Machine Learning offre un'alternativa di gran lunga più efficiente per migliorare le previsioni e prendere decisioni basate sui dati. Inoltre, svolge un ruolo molto importante nella vita quotidiana, in quanto trova molteplici applicazioni.

### Pre-annotation

Sulla base del dizionario, fornito dagli esperti di dominio, è stata avviata la fase di pre-annotation che ha permesso di etichettare i files testuali ai fini dell'apprendimento supervisionato da parte del modello.




Figura 2.16: Pre-annotazione mediante dizionario fornito dagli esperti di dominio

### Addestramento del modello

Al termine dell'annotazione delle entità è possibile procedere con l'addestramento del modello. Poiché il data-set è formato esclusivamente dall'abstract, non si pone il problema di suddivisione dei files, ciò riduce la possibilità di correlazione dei dati potenzialmente dovuta alla ripartizione dello stesso documento in parte nel training, nel validation oppure nel test set.

Per gestire efficientemente il set di documenti, nella fase di addestramento, la suddivisione avviene nel seguente modo:

- **Training set:** è un insieme di documenti già pre-annotati ed annotati per addestrare il modello. L'obiettivo è insegnare al machine learning model a riconoscere le entità e relazioni correttamente all'interno di documenti che non sono stati ancora annotati.
- **Test set:** è un insieme di documenti annotati usati per testare il modello addestrato. La necessità di un sub-set rappresentativo di quello documentale è motivata dagli scopi diagnostici che i risultati evidenziano. Aiuta a comprendere i punti di forza e debolezza del modello: entità e relazioni. Infatti, il validation set è utilizzato per la regolazione degli iperparametri. Nella regolazione degli iperparametri è possibile tenere in considerazione precision e recall.
- **Blind set:** Tale insieme è utile, al termine del perfezionamento del modello, per valutare le prestazioni dello stesso. Le informazioni contenute nel blind set non devono essere prese in considerazione dall'utente nel definire il modello di apprendimento. I risultati che devono essere riportati sono quelli relativi all'F1 scores.

I tre sottoinsiemi di dati devono essere disgiunti e tipicamente suddivisi in 70% per il training, 23% per il test e 7% per il blind set. Bisogna porre attenzione alla correlazione fra dati poichè queste possono condurre a specializzazione del modello e di conseguenza ad una sopravvalutazione delle performance.

Last trained on: Sep 22, 2021 4:15:53 PM  
Last evaluated on: Sep 22, 2021 4:18:06 PM

[Train](#) [Evaluate](#) [Train & Evaluate](#) [Go Back to View Mode](#)

| Document Set                                                 | Task Status |
|--------------------------------------------------------------|-------------|
| <input checked="" type="checkbox"/> All                      |             |
| <input type="checkbox"/> Treatment of meningioma and ...t... |             |

☒ Create new sets by splitting the selected document sets

Ratio  
Enter the percentage of documents to include in each set.

|    |                                |
|----|--------------------------------|
| 70 | Training Set (70% Recommended) |
| 23 | Test Set (23% Recommended)     |
| 7  | Blind Set (7% Recommended)     |

**Figura 2.17:** Suddivisione data-set

## Evaluation

Le tre metriche utilizzate per la valutazione del modello sono le seguenti:

- **Precision:** è una misura di esattezza o fedeltà. La precision è definita come il numero di veri positivi (cioè quelli correttamente classificati) fratto il numero totale di elementi etichettati come appartenenti alla classe;

$$\text{Precision} = \frac{\text{TruePositives}}{\text{TruePositives} + \text{FalsePositives}}$$

- **Recall:** è una misura di completezza. La recall è definita come il numero di veri positivi diviso il numero totale di elementi che effettivamente appartengono alla classe;

$$\text{Recall} = \frac{\text{TruePositives}}{\text{TruePositives} + \text{FalseNegatives}}$$

- **F1 score:** è una misura complessiva delle prestazioni. Si definisce come la media armonica di precision e recall;

$$\text{F1} = \frac{2 * \text{Precision} * \text{Recall}}{\text{Precision} + \text{Recall}}$$

Prima di procedere con la valutazione delle performance è bene precisare che, rispetto ai progetti precedenti, il modello è stato addestrato su un numero di articoli inferiore ed esclusivamente sul contenuto testuale dell'abstract. Inoltre, in fase di preprocessing, così come per i precedenti progetti, non è stata valutata alcuna tipologia di correlazione fra articoli. Intorno le entità, queste hanno subito alcune modifiche come già spiegato nei paragrafi precedenti.

| Entity Types               | F1   | Precision | Recall | % of Total Annotations | % of Corpus Density (by number of words) | % of Documents that Contain This Type |
|----------------------------|------|-----------|--------|------------------------|------------------------------------------|---------------------------------------|
| Adverse_Effect             | 0.97 | 1         | 0.94   | 4% (78/1769)           | 0% (78/45551)                            | 39% (25/64)                           |
| Chemotherapy               | 0.99 | 1         | 0.98   | 12% (212/1769)         | 0% (212/45551)                           | 99% (38/64)                           |
| Glioblastoma               | 0.97 | 0.98      | 0.97   | 17% (299/1769)         | 1% (299/45551)                           | 73% (47/64)                           |
| Immunotherapy              | 0.21 | 1         | 0.12   | 1% (17/1769)           | 0% (17/45551)                            | 11% (7/64)                            |
| Laser_Therapy              | N/A  | N/A       | N/A    | 0% (0/1769)            | 0% (0/45551)                             | 0% (0/64)                             |
| Magnetic_Resonance_Imaging | 0.98 | 0.98      | 0.98   | 3% (52/1769)           | 0% (52/45551)                            | 25% (16/64)                           |
| Molecular_classification   | 0.74 | 0.98      | 0.6    | 3% (49/1769)           | 0% (49/45551)                            | 23% (15/64)                           |
| Radiotherapy               | 0.96 | 0.97      | 0.95   | 8% (147/1769)          | 0% (147/45551)                           | 50% (32/64)                           |
| Response_Assessment        | 0.95 | 0.95      | 0.96   | 8% (136/1769)          | 0% (136/45551)                           | 63% (40/64)                           |
| Response_to_therapy        | 0.96 | 0.96      | 0.96   | 23% (414/1769)         | 1% (414/45551)                           | 84% (54/64)                           |
| Surgery                    | 0.24 | 1         | 0.2    | 3% (59/1769)           | 0% (59/45551)                            | 41% (26/64)                           |
| Target_Therapy             | 0.98 | 1         | 0.96   | 4% (76/1769)           | 0% (76/45551)                            | 28% (18/64)                           |
| Therapy                    | 0.47 | 1         | 0.21   | 8% (150/1769)          | 0% (150/45551)                           | 77% (49/64)                           |
| Trial                      | 0.8  | 0.92      | 0.72   | 5% (80/1769)           | 0% (80/45551)                            | 27% (17/64)                           |
| Vaccine_Therapy            | N/A  | N/A       | N/A    | 0% (0/1769)            | 0% (0/45551)                             | 0% (0/64)                             |
| Overall Statistics         | 0.91 | 0.97      | 0.85   | 100% (1769/1769)       | 4% (1769/45551)                          | 100% (64/64)                          |

Figura 2.18: Performance

Le performance evidenziano le seguenti criticità:

- Le entità *Laser\_Therapy* e *Vaccine\_Therapy* non vengono annotate poiché la tematica non è rilevata negli abstracts;
- Le informazioni riguardanti le entità *Immunotherapy* e *Surgery* sono scarsamente rappresentate nell'abstract;

- Conferma dello scarso contenuto informativo degli abstracts è l'entità *Therapy*, anch'essa in grado di recuperare pochi documenti;

Oltre al summary è possibile considerare, con maggiore dettaglio per le performance, la **matrice di confusione**.

Essa presenta:

- sulle righe la classe effettiva, cioè le entità fornite nel dictionary per la fase di pre-annotation ;
- sulle colonne i valori predetti, in fase di evaluation, dal modello;
- Sulla diagonale principale le entità predette correttamente;
- La O (Outside) indica le entità che il modello avrebbe dovuto classificare e che non ha etichettato;

| Entity Type        | Adverse_Effect | Chemotherapy | Glioblastoma | Immunotherapy | Magnetic_Reson... | Molecular_Glial... | O     | Radiotherapy | Response_Assess... | Response_To_R... | Surgery | Target_Therapy | Therapy | Total |
|--------------------|----------------|--------------|--------------|---------------|-------------------|--------------------|-------|--------------|--------------------|------------------|---------|----------------|---------|-------|
| Adverse_Effect     | 76             | 0            | 0            | 0             | 0                 | 0                  | 0     | 0            | 0                  | 0                | 0       | 0              | 0       | 76    |
| Chemotherapy       | 0              | 311          | 0            | 0             | 0                 | 0                  | 1     | 0            | 0                  | 0                | 0       | 0              | 0       | 313   |
| Glioblastoma       | 0              | 0            | 207          | 0             | 0                 | 0                  | 0     | 0            | 0                  | 0                | 0       | 0              | 0       | 207   |
| Immunotherapy      | 0              | 0            | 0            | 2             | 0                 | 0                  | 0     | 0            | 0                  | 0                | 0       | 0              | 0       | 2     |
| Magnetic_Reson...  | 0              | 0            | 0            | 0             | 68                | 0                  | 0     | 0            | 0                  | 0                | 0       | 0              | 0       | 68    |
| Molecular_Glial... | 0              | 0            | 0            | 0             | 0                 | 44                 | 0     | 0            | 0                  | 0                | 0       | 0              | 0       | 44    |
| O                  | 0              | 0            | 7            | 0             | 1                 | 0                  | 40092 | 6            | 4                  | 17               | 0       | 0              | 0       | 40120 |
| Radiotherapy       | 0              | 0            | 0            | 0             | 0                 | 0                  | 0     | 142          | 0                  | 0                | 0       | 0              | 0       | 142   |
| Response_Assess... | 0              | 0            | 0            | 0             | 0                 | 0                  | 0     | 0            | 122                | 0                | 0       | 0              | 0       | 122   |
| Response_To_R...   | 0              | 0            | 0            | 0             | 0                 | 0                  | 0     | 0            | 0                  | 605              | 0       | 0              | 0       | 605   |
| Surgery            | 0              | 0            | 0            | 0             | 0                 | 0                  | 0     | 0            | 0                  | 0                | 12      | 0              | 0       | 12    |
| Target_Therapy     | 0              | 0            | 0            | 0             | 0                 | 0                  | 0     | 0            | 0                  | 0                | 0       | 71             | 0       | 71    |
| Therapy            | 0              | 0            | 0            | 0             | 0                 | 0                  | 0     | 0            | 0                  | 0                | 0       | 0              | 44      | 44    |
| Total              | 0              | 0            | 0            | 0             | 0                 | 0                  | 13    | 0            | 0                  | 0                | 0       | 0              | 67      | 67    |
| Total              | 76             | 311          | 204          | 2             | 68                | 44                 | 40097 | 148          | 127                | 426              | 12      | 71             | 44      | 40661 |

Figura 2.19: Matrice di confusione

La matrice di confusione mostra sulla diagonale principale la bontà del modello. La riga O mostra che le entità non etichettate sono in numero ridotto.

## 2.4 Deploy

Una volta ottenuto un modello che rappresenta significativamente i dati è possibile effettuare il deployment sul cloud di IBM. Con l'uso del *Model ID* è possibile integrare più servizi del catalogo di IBM watson. Nel particolare, il progetto prevede l'integrazione di Watson Knowledge Studio con Discovery.




Figura 2.20: Interfacciamento WKS con Discovery

## 2.5 Data Collection in Watson Discovery

Addestrato il modello di Machine Learning in WKS, il passo successivo consiste nel creare un'istanza del **servizio di Watson Discovery (WD)**. L'obiettivo è creare una collezione di documenti su cui svolgere una ricerca, mediante query svolte dall'utente.

### 2.5.1 Creazione della Data Collection

Una **Data Collection** è una collezione contenente tutti i documenti di interesse. In particolare, la versione Lite di Watson Discovery di cui si usufruisce presenta alcune limitazioni:

- il numero massimo di documenti caricabili è pari a 1000;
- la dimensione dei file può essere al massimo 50 MB;
- non è possibile caricare file in formato .txt.

Considerando tali limitazioni, la data collection è stata creata caricando all'interno del servizio **70 documenti in formato .pdf**. I documenti che compongono la collection sono un sottoinsieme degli articoli considerati per lo sviluppo del modello in Watson Knowledge Studio, ovvero quelli che fanno parte del dataset Parte 1. La differenza sostanziale risiede nel fatto che, mentre in Watson Knowledge Studio sono stati caricati unicamente le porzioni di testo relative all'abstract di ciascun articolo, in Watson Discovery sono stati caricati i file in formato .pdf, ciascuno contenente l'intero articolo.

Ad ogni modo, con un piano a pagamento dei servizi, è possibile aumentare la scalabilità e caricare nella collection un numero più elevato di documenti.

Effettuato il caricamento dei documenti in Watson Discovery, essi vengono automaticamente processati. Ciò permette di ottenere in output l'**estrazione di alcune caratteristiche (enrichments)**, come ad esempio:

- *Entity Extraction*: permette di collegare un modello sviluppato in Watson Knowledge Studio per estrarre le entità definite in esso dai documenti della collection;
- *Sentiment Analysis*: individua il sentiment e le opinions dei documenti forniti come input;
- *Keyword Extraction*: individua le parole più rilevanti all'interno dei documenti.

## 2.5.2 Data Configuration

Una volta caricati i documenti all'interno della collection, è possibile svolgere alcune **operazioni di configurazione dei dati** per migliorare la qualità del sistema in Watson Discovery.

### Tagging mediante il servizio Smart Document Understanding

A seguito del caricamento, Watson Discovery riconosce di default un unico field, identificato dall'etichetta *text*, all'interno dei documenti.

Watson Discovery può essere **addestrato mediante il servizio Smart Document Understanding (SDU)** per estrarre automaticamente dai documenti i campi di interesse, in modo da **migliorare le prestazioni del sistema** per quanto riguarda i risultati che vengono restituiti dalle query.

Più nel particolare, il servizio SDU permette di svolgere un'operazione di tagging manuale e visuale dei vari campi che compongono un documento completo, indicando se una porzione di esso rappresenta l'header, il titolo, l'autore, il testo, e così via. La **fase di training** mediante SDU consiste nel tagging manuale di massimo 20 articoli che compongono il training set per l'addestramento del modello. Date le limitazioni del piano Lite che ha permesso il caricamento di un numero esiguo di articoli (pari a 70), il training è stato svolto, effettuando il tagging di documenti con forti differenze in termini di layout e impaginazione, in modo tale che il modello in Watson Discovery fosse in grado di apprendere quante più strutture



differenti di documento. Proseguendo con il tagging manuale, Watson Discovery impara automaticamente come effettuare le annotazioni, predicendo i fields.



Figura 2.21: Tagging dei documenti

Una volta individuati i fields all'interno dei documenti, è possibile **selezionare quali campi sono ritenuti rilevanti**. In tal caso, i campi selezionati sono:

- *text*;
- *title*;
- *subtle*;
- *table of contents*.




Figura 2.22: Elenco dei fields abilitati

## Segmentation dei documenti

Un'ulteriore operazione da svolgere per migliorare le prestazioni del sistema è la **document segmentation** che consiste nel dividere ciascun documento in base ai campi indicati per lo splitting. Ad esempio, supponendo che lo split debba essere svolto in base al campo *subtitle*, un documento verrà diviso in tanti segmenti in corrispondenza di ciascun sottotitolo. Questa operazione fa in modo che ciascun segmento ottenuto dalla segmentazione rappresenti un documento distinto da arricchire, indicizzare e restituire come un risultato singolo di una query. In base allo split, a partire da 70 articoli, il numero complessivo di documenti ottenuti dalla segmentation risulta pari a 1086.

### Improve query results by splitting your documents

You can split your documents into segments based on fields. Once split, each segment is a separate document that will be enriched, indexed, and returned as a query separately. [Learn more.](#)



Split document on each occurrence of

subtitle

▼

⊖

**Figura 2.23:** Campo di segmentation

## Enrichment Addition

A seguito delle operazioni appena svolte, è possibile **selezionare quali fields devono essere aggiunti agli enrichments**. Tra gli enrichment è stato inserito l'**Entity Extraction per collegare il modello creato in Watson Knowledge Studio**, in modo da individuare le entità del dominio medico. A tal fine, occorre inserire il *Model ID* del modello di Machine Learning di WKS all'interno della sezione *Custom Model ID* dell'*Entity Extraction* di Watson Discovery (attenzione: affinché sia possibile connettere il modello di WKS con WD, occorre che le 2 istanze dei servizi siano allocate nella stessa Region del cloud - considerando il piano Lite, entrambe sono state allocate in London).




Figura 2.24: Enrichments aggiunti al sistema

A seguito delle aggiunte effettuate, l'interfaccia di Watson Discovery si presenta come riportato nella seguente figura.




Figura 2.25: Interfaccia di Watson Discovery in seguito all'aggiunta di enrichments

### 2.5.3 Schema dei dati

Svolta la configurazione dei dati, Watson Discovery permette di **visualizzare lo schema dei dati** della collection attraverso 2 modalità:

- **Collection view**: riporta i fields identificati nella data collection e gli enrichment aggiunti;

- **Document view**: fornisce un livello di dettaglio maggiore, riportando, per ogni documento, i fields identificati con i relativi enrichment.

La seguente figura riporta un esempio di entità mostrata attraverso la *Collection view*. Come si può notare, generalmente, un'entità è identificata da più campi (*text*, *type*, *count*).

| Fields                                                                                                 | Example values |
|--------------------------------------------------------------------------------------------------------|----------------|
| enriched_text.entities.text                                                                            | temozolomide   |
| enriched_text.entities.type                                                                            | Chemotherapy   |
| enriched_text.entities.relevance<br><small>Range: 0.0-1.0</small>                                      | --             |
| enriched_text.entities.count                                                                           | 1              |
| enriched_text.entities.sentiment.score<br><small>&gt;0: positive; 0.0: neutral; &lt;0 negative</small> | --             |
| enriched_text.entities.disambiguation.name                                                             | --             |
| enriched_text.entities.disambiguation.subtype                                                          | NONE           |
| enriched_text.entities.disambiguation.dbpedia_resource                                                 | --             |

[Show fewer fields](#)

**Figura 2.26:** Entity visualizzata mediante Collection view

## 2.5.4 Discovery Query

A seguire, si riporta un **esempio di query**, svolto attraverso Watson Discovery, che mira ad estrarre dai documenti informazioni relative ad uno dei parametri citati in precedenza che funge da end-point della ricerca oncologica (OS, PFS, ORR + gli ulteriori parametri individuati con gli esperti di dominio, ovvero KPS, Objective Response Rate, NSR PSQI, etc.).

Le query possono essere svolte in **2 modalità**:

- *Natural Language*
- *Discovery Query Language*

In più, è possibile anche svolgere operazioni di filtraggio per limitare il numero di documenti o effettuare un'analisi aggregata sui risultati.

La **query** svolta nella seguente figura individua tutti i documenti in cui è presente l'overall survival (presente nelle forme *OS*, *overall survival* e *Overall survival*) ed effettua un'operazione di filtraggio sull'entità *Chemotherapy*, in modo

da restituire come risultato i documenti che contengono tale entità e presentano il parametro richiesto.

Search for documents [Edit in query language](#)

Use natural language [Use the Discovery Query Language](#)

Satisfy  of the following rules

| Field                       | Operator | Value            |
|-----------------------------|----------|------------------|
| enriched_text.entities.text | contains | Overall survival |
| enriched_text.entities.text | contains | overall survival |
| enriched_text.entities.text | contains | OS               |

+ Include analysis of your results

---

Filter which documents you query [Edit in query language](#)

Satisfy  of the following rules

| Field                       | Operator | Value        |
|-----------------------------|----------|--------------|
| enriched_text.entities.type | contains | Chemotherapy |

+ Add rule  
+ Add group of rules

enriched\_text.entities.type:"Chemotherapy"

> More options

[Run query](#) [Close](#)

Figura 2.27: Esempio di query

La seguente figura riporta i **risultati** ottenuti dalla query. Il sistema ritorna 54 documenti, indicando, per ognuno di essi, le entità, le keywords e le porzioni in cui sono presenti le informazioni richieste.

| Results                                                                                                                                                                                   |                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                             |
|-------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|---------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| Showing 10 of 54 matching documents                                                                                                                                                       |                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                             |
| <div> <div></div> <div>Multi-Parametric Deep Learning Model for Prediction of Overall Survival after Postoperative Concurrent Chemoradiotherapy in Glioblastoma Patients.pdf</div> </div> | Sentiment                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                   |
|                                                                                                                                                                                           | positive                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                    |
|                                                                                                                                                                                           | Entity                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                      |
|                                                                                                                                                                                           | overall survival                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                            |
|                                                                                                                                                                                           | Keywords                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                    |
|                                                                                                                                                                                           | overall survival                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                            |
| Text                                                                                                                                                                                      | <p>"...Root mean squared error and correlation coefficient of each model for overall survival RMSE, root mean squared error, a Described as mean <math>\pm</math> standard deviation, Table 3. Harrell's concordance index (C-index) and integrated area under the time-dependent receiver operating characteristic curve (AUC) values of each model for overall survival prediction..."</p> <p>"...Root mean squared error and correlation coefficient of each model for overall survival prediction. Model (included Features RMSE (Months) a Correlation Coefficient GLYPH (LA) client Table 3. Harrell's concordance index (C-index) and integrated area under the time-dependent receiver operating characteristic curve (AUC) values of each model for overall survival prediction..."</p> <p>"...Kaplan-Meier survival curves for overall survival 2.2. Model Performance Measured by C-index and Integrated Area Under the Time-Dependent Receiver Operating Characteristic (ROC) Curve (AUC) Table 2 lists the root mean squared error (RMSE), the square root of the mean squared residuals, and Pearson's correlation coefficient between the ground truth and predicted OS in each model..."</p> <p>"...Kaplan-Meier survival curves for overall survival. Model Performance Measured by C-index and Integrated Area Under the Time-Dependent Receiver Operating Characteristic (ROC) Curve (AUC) Table 2 lists the root mean squared error (RMSE), the square root of the mean squared residuals, and Pearson's correlation coefficient between the ground truth and predicted OS in each model..."</p> <p>"...Therefore, we calculated Harrell's C-index and AUC values of each model, and Table 3 lists the C-indexes and AUC values of the models for OS prediction..."</p> |

Figura 2.28: Porzione del risultato della query

## Capitolo 3

# Analisi ed interpretazione dei risultati

### 3.1 Analisi dei risultati tra le versioni del progetto

A seguire, si effettua un confronto tra la versione precedente del progetto, sviluppata a Luglio 2021, e quella attuale (argomento di tale documentazione) di Settembre 2021. Il confronto viene svolto da 3 punti di vista differenti:

- confronto sul dataset;
- confronto sul preprocessing dei dati;
- confronto sulle prestazioni dei modelli.

#### 3.1.1 Confronto sul dataset

Su indicazione degli esperti di dominio è stato selezionato il set di documenti relativi la Parte 1 per lo svolgimento del progetto, a differenza del precedente sviluppo progettuale che ha riguardato l'utilizzo della Parte 2. Tale differenza nella scelta dei dati non permette un confronto valido sulle versioni del progetto, ma consente di esprimere delle considerazioni significative:

- la precedente versione si basava sull'ingestion dell'intero articolo;
- la versione attuale si focalizza esclusivamente sull'ingestion dell'abstract di ciascun articolo.

### 3.1.2 Confronto sul preprocessing dei dati

Di rilevante importanza risulta essere la differenza dell'elaborazione preliminare svolta sui documenti rispetto al precedente progetto. Infatti, come più volte evidenziato, il caricamento degli articoli in formato .pdf nella piattaforma di Watson Knowledge Studio comportava problematiche a causa della formattazione intrinseca dei documenti, per cui i testi venivano fusi senza un ordine coerente lessico-grafico e grammaticale. Nell'attuale versione del progetto è stato possibile estrarre il contenuto informativo della prima pagina conservando il senso delle frasi senza che esse potessero unirsi ad altre. Altrimenti l'unione del testo si sarebbe verificata a causa dell'adiacenza di paragrafi nel layout di pagina. Ad ogni modo, l'elaborato evidenzia la possibilità che, in alcuni casi, si verifichi la criticità riguardo l'inversione di alcuni segmenti. Per questa criticità sono state fornite 2 proposte di risoluzione per il sequenziamento corretto dei segmenti di testo.

Inoltre, col fine di evidenziare maggiori relazioni nella fase di annotazione in Watson Knowledge Studio, cercando di ridurre i limiti tecnologici del servizio di IBM, è stata effettuata una regolarizzazione del testo che consiste nell'eliminazione del punto di fine periodo e nella sostituzione del punto di ciascuna cifra decimale con la virgola.

### 3.1.3 Confronto sulle prestazioni dei modelli

Le 2 versioni dell'elaborato prevedono scelte progettuali di base differenti che non permettono un confronto valido, ma consentono di effettuare considerazioni significative. La differenza fondamentale consiste nella **ridefinizione del modello**:

- l'entità *Tumor* è stata specializzata in *Glioblastoma*;
- per ciascuno tipo entità sono stati considerati i rispettivi sottotipi;
- l'entità *Therapy* prevede una gerarchia di specializzazione in sottotipi di entità che a loro volta si specializzano ulteriormente;
- è stata effettuata una rivalutazione delle relazioni per rilassare i vincoli della meta-analisi tradizionale. Nel particolare, sono stati considerati 7 nuovi parametri da aggiungere ai 3 end-points (OS, DFS, PFS) della meta-analisi tradizionale.

A fronte di una riduzione che riguarda sia il numero di documenti (279 nell'attuale versione contro 370 della versione precedente) che il contenuto (abstract contro

documento intero) e di un utilizzo di dataset differenti (Parte 1 e Parte 2), le 2 misure di prestazioni risultano compatibili in quanto il dominio applicativo è lo stesso e le performance misurate per entità comuni sono pressoché le stesse. Ad ogni modo, la diversità dei dataset utilizzati potrebbe far variare significativamente il valore della F1 score, in quanto ci potrebbe essere varietà negli argomenti dei documenti utilizzati nelle 2 versioni. Ciò evidenzia che, per quanto compatibili, i risultati ottenuti dalle 2 versioni non sono confrontabili.

Inoltre, nel nuovo sviluppo, rispetto a quello precedente, si può intuire una minore correlazione nei dati legato al numero ristretto di contenuto informativo relativo all'abstract. Infatti, la versione precedente, basata sul caricamento degli articoli nella loro interezza, richiedeva la separazione di essi in più documenti a causa delle limitazioni della tecnologia di Watson Knowledge Studio. Di conseguenza, tale suddivisione del dataset in training, test e blind sets, conduce a possibile correlazione e quindi sopravvalutazione delle performance.